

# Hw3 Shitot: Gil & Zakh

א) (7 נקודות) הוכיחו כי השוויון ההפוך גם מתקיים:

$$\forall k = 1, \dots, n: \sum_{i=1}^k \lambda_{n-i+1}(X+Y) \geq \sum_{i=1}^k \lambda_{n-i+1}(X) + \lambda_{n-i+1}(Y)$$

(1)

Ky-Fan:

$$\forall k = 1, \dots, n: \sum_{i=1}^k \lambda_i(A+B) \leq \sum_{i=1}^k \lambda_i(A) + \lambda_i(B)$$

$$\sum_{i=1}^k \lambda_i(-A-B) \leq \sum_{i=1}^k \lambda_i(-A) + \lambda_i(-B)$$

$$\sum_{i=1}^k -\lambda_{n-i+1}(A+B) \leq \sum_{i=1}^k -\lambda_{n-i+1}(A) - \lambda_{n-i+1}(B)$$

$$\Rightarrow \sum_{i=1}^k \lambda_{n-i+1}(A+B) \leq \sum_{i=1}^k \lambda_{n-i+1}(A) + \lambda_{n-i+1}(B)$$

(2)

ב) (7 נקודות) הוכיחו/הפריכו:

בhinתן שלמים  $n \leq k \leq n$  ומטריצה סימטרית  $S \in X$ , נסמן את הערכים העצמיים שלה על ידי:  $\lambda_1(X) \geq \dots \geq \lambda_n(X)$ .  
נגידר את הפונקציה:  $|X| = \sum_{i=1}^k |\lambda_i(X)|$  - קולומר הפונקציה מחזירה את סכום הערכים המוחלטים של  $k$  הערכים העצמיים הגדולים ביותר של המטריצה  $X$ . אזי, הפונקציה הנ"ל היא נורמה מעלה מרחב המטריצות הסימטריות ממשיות  $n \times n$ .

A function  $\|\cdot\| : \mathcal{X} \rightarrow \mathbb{R}$  is a norm, if

- ①  $\forall x \in \mathcal{X} \quad \|x\| \geq 0$ , and  $\|x\| = 0$  if and only if  $x = 0$  (positivity)
- ②  $\forall x, y \in \mathcal{X} \quad \|x+y\| \leq \|x\| + \|y\|$  (triangle inequality)
- ③  $\forall \alpha \in \mathbb{R}, x \in \mathcal{X}: \quad \|\alpha x\| = |\alpha| \cdot \|x\|$  (homogeneity)

$$||X|| = \sum_{i=1}^k |\lambda_i(x)| \geq 0 \quad x \in S^n \quad (2)$$

$$x \in \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \in \mathbb{S}^2$$

$$\phi = \|x\| = \lambda_1(x) = 0 \quad \lambda_1 = 1 \quad \lambda_2 = 0 \quad \lambda_1 \geq \lambda_2 \geq \lambda_3 \geq \dots \geq \lambda_n$$

$$x \neq 0 \quad \text{ולכן} \quad \lambda_1 > 0 \quad \text{ולכן} \quad \|x\| > 0$$

$$\text{וכך } \|x\| > 0$$

שאלה 2

תהי  $A \in \mathbb{R}^{m \times n}$  כך ש- $m \leq n$ . נסמן ב- $\sigma_1, \dots, \sigma_n$  את הערכים הסינגולרים של  $A$ .

$$\text{נגיד}: \bar{A} = \begin{pmatrix} A \\ I_n \end{pmatrix} \in \mathbb{R}^{(m+n) \times n}$$

(1) הראה כי הערכים הסינגולרים של  $\bar{A}$  הם  $\bar{\sigma}_i = \sqrt{1 + \sigma_i^2}$ .

$$\bar{A}^T = (A^T \ I_n) \Rightarrow \bar{A}^T \bar{A} = (A^T \ I_n) \begin{pmatrix} A \\ I_n \end{pmatrix} = A^T A + I_n$$

$$\Rightarrow \lambda_i(\bar{A}^T \bar{A}) = \lambda_i(A^T A + I) = \lambda_i(A^T A) + 1$$

$$\Rightarrow \lambda_i(\bar{A}) = \sqrt{\lambda_i(\bar{A}^T \bar{A})} = \sqrt{\lambda_i(A^T A) + 1} = \sqrt{\lambda_i(A) + 1}$$

(2)

תהי  $A \in \mathbb{R}^{m \times n}$  כך ש- $m \leq n$ . נסמן ב- $\sigma_1, \dots, \sigma_n$  את הערכים הסינגולרים של  $A$ .

$$\text{נגיד}: \bar{A} = \begin{pmatrix} A \\ I_n \end{pmatrix} \in \mathbb{R}^{(m+n) \times n}$$

מצאו פירוק SVD של  $\bar{A}$  בהינתן פירוק SVD של  $A$ .

$$A = U \Sigma V^T = U_r \Sigma_r V_r^T = \sum_{i=1}^r \sigma_i u_i v_i^T$$

1 2 (2)

$$\bar{A} = \begin{pmatrix} U\Sigma V^T \\ I_n \end{pmatrix}$$

- e *orthogonal* *approx* *diag* *U*<sub>n</sub>*eigen* (2)

$\text{Hence } \bar{\sigma}_i = \sqrt{1 + \sigma_i^2}$

$$\bar{A}\bar{A}^T = \begin{pmatrix} U\Sigma V^T \\ I_n \end{pmatrix} \begin{pmatrix} I_n & U\Sigma V^T \end{pmatrix} = \begin{pmatrix} U\Sigma V^T & U\Sigma V^T \end{pmatrix}$$

" *unitary* *matrix* *is* *inverted* *as* *U*<sub>i</sub> = *U*<sub>i</sub> *right* *of* *A*

" *A* *right* *of* *V*<sub>i</sub> *is* *diag*

$\text{Hence } \bar{v}_i = \frac{\bar{A}^T \cdot u_i}{\bar{\sigma}_i}$

" *from* *line* *of* *U*<sub>r</sub> *is* *U*<sub>r</sub> *right* *of* *A*

" *so* *the* *SVD* *is* *given* *by*

$\bar{A} = \bar{U} \cdot \bar{\Sigma} \cdot \bar{V}$  " *as* *defined* *as* *the* *singular* *value*

Q3

$$B = A \circ A^T = \begin{pmatrix} 0 & 1 & 1 \\ 0 & 1 & -1 \\ 1 & -1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 0 & 1 \\ 1 & 1 & 0 \\ 1 & -1 & 0 \end{pmatrix} = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{pmatrix} \Rightarrow \begin{cases} \lambda_{1,2} = 2 \\ \lambda_3 = 1 \end{cases}$$

(1c)

$$(B - 2I)x = 0 \Rightarrow \left( \begin{array}{ccc|c} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{array} \right) \Rightarrow x_3 = 0 \Rightarrow \begin{pmatrix} f \\ g \\ 0 \end{pmatrix} \Rightarrow \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \Rightarrow U = I$$

$$(B - I)x = 0 \Rightarrow \left( \begin{array}{ccc|c} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{array} \right) \Rightarrow x_1 = x_2 = 0 \Rightarrow \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \Rightarrow \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

$$\tilde{\sigma}_{1,2}(A) = \sqrt{2}, \quad \tilde{\sigma}_3 = 1$$

$$V_1 = \frac{A^T \cdot U_1}{\sqrt{2}} = \frac{1}{\sqrt{2}} \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}, \quad V_2 = \frac{A^T \cdot U_2}{\sqrt{2}} = \frac{1}{\sqrt{2}} \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix}, \quad V_3 = \frac{A^T \cdot U_3}{\sqrt{2}} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$$

$$\Rightarrow A = I \circ \underbrace{\begin{pmatrix} \sqrt{2} & 0 & 0 \\ 0 & \sqrt{2} & 0 \\ 0 & 0 & 1 \end{pmatrix}}_{U \cdot \Sigma \cdot V^T} \circ \begin{pmatrix} 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ 0 & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ 1 & 0 & 0 \end{pmatrix}$$

(2)

ההסבב בפונקציית

$$\boxed{\text{Rank}(A) = 3}$$

ההסבב בפונקציית

$$\begin{pmatrix} 0 & 1 & 1 \\ 0 & 1 & -1 \\ 1 & 0 & 0 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 1 & 1 & -1 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 1 & 1 & -1 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

ככל שטחן גודל הערך הא眞 של מטריצה הולך וגדל

בצורה דדרתית

$$\{( \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \end{pmatrix} )\} \subseteq \text{Im}(A) = \text{Im}(A^T) = \mathbb{R}^3$$

(2)

$$N(A) = N(A^T) = \{ \} \quad \text{ההסבב בפונקציית}$$

?

כתבו את המטריצה הפסאודו ההפכית  $A^+$ .

$$\tilde{\Sigma}^{-1} = \text{diag} \left( \frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}, 1 \right) \Rightarrow \Sigma^+ = \tilde{\Sigma}^{-1}$$

$$U^T = I^T = I$$

$$\boxed{A^+ = \begin{pmatrix} 0 & 0 & 1 \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \end{pmatrix} \cdot \begin{pmatrix} 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix} \cdot I}$$

## שאלה 4

תהי  $R \in \mathbb{R}^{m \times n}$  מטריצה כלשהי, ויהי  $Q \in \mathbb{R}^{n \times n}$ ,  $R \in \mathbb{R}^{m \times m}$  מטריצות אורתוגונליות. הוכיחו את הטענות הבאות:

$$\|RYQ\|_F = \|Y\|_F \quad (1)$$

הנְּזָרֶת

$$\|R Y Q\|_F^2 = \text{Tr}(Q^T Y^T R^T R Y Q) =$$

$$= \text{Tr}(Q^T Q R^T R Y^T Y) = \text{Tr}(Y^T Y) = \|Y\|_F^2$$

$\text{Tr}(AB) = \text{Tr}(BA)$        $A^T A = I$        $\| \cdot \|_F$  מוגדר

$\lambda_1 \geq \dots \geq \lambda_n$

$$\|R Y Q\|_F = \|Y\|_F \quad \square$$

$$A = U\Sigma V^T = U_r \Sigma_r V_r^T = \sum_{i=1}^r \sigma_i u_i v_i^T$$

המטריצה:  $A^\dagger = V\Sigma^T U^T$  נקראת המטריצה הפסאודו-הופכית של  $A$ .

תהי  $Y \in \mathbb{R}^{m \times n}$  מטריצה כלשהי, ויהי  $R \in \mathbb{R}^{m \times m}$ , נ' כאשר:

אורטוגונליות. הוכיחו את הטענות הבאות:

$$\langle \mathbf{A}, \mathbf{B} \rangle = \sum_{i \in [m], j \in [n]} .$$

$$\|RYQ\|_F = \|Y\|_F \quad .1$$

$$\| RYQ \|_2 = \| Y \|_2 \quad .2$$

$$\|R^T Q\|_2 = \sqrt{\langle R^T Q, R^T Q \rangle} = \sqrt{\sum_{i \in [m]} \sum_{j \in [n]} (R^T Q)_{ij} \cdot (R^T Q)_{ij}} = \sqrt{\sum_{j=0}^n \sum_{i=0}^m R_{ij} Q_{ij} R_{ij} Q_{ij}}$$

$\Rightarrow$   $\forall i \in [n] \quad R_i^T Q =$

$$= \sqrt{\sum_{j=0}^n \sum_{i=0}^m R_{ij} \cdot R_{ij} Q_{ij} Q_{ij} Y_{ij} Y_{ij}} = \sqrt{\sum_{i \in [m]} \sum_{j \in [n]} Y_{ii} \cdot Y_{ii}} = \sqrt{\langle Y, Y \rangle} = \|Y\|_2 \quad \blacksquare$$

גנרטור  
הנורמליזציה  
הטביעה  
הטביעה  
הטביעה  
הטביעה

שאלה 5

$A \in \mathbb{R}^{m \times n}$

① מה הוכיחו את הטענה הבאה, שהיא הטענה המקבילה למשפט ריל' עבור  
טטריצות לא סימטריות:  
 $\max_{x \in \mathbb{R}^m, y \in \mathbb{R}^n, \|x\|_2 = \|y\|_2 = 1} x^T A y = \sigma_1$   
 $\min_{x \in \mathbb{R}^m, y \in \mathbb{R}^n, \|x\|_2 = \|y\|_2 = 1} x^T A y = -\sigma_1$

בסוף, הוכיחו כי:

כלורן מינימיזציה - SVD

$$A = U \Sigma V^T$$

$$\Rightarrow \max_{x \in \mathbb{R}^m, y \in \mathbb{R}^n, \|x\|_2 = \|y\|_2 = 1} (x^T A y) = \max_{x \in \mathbb{R}^m, y \in \mathbb{R}^n, \|x\|_2 = \|y\|_2 = 1} (x^T U \Sigma V^T y)$$

$$\text{לפניהם, } \bar{y} = V_r^T y \in \mathbb{R}^r, \quad \bar{x} = U_r^T x \in \mathbb{R}^r \quad | \text{ נס}$$

$$\|\bar{x}\|_2 = \|U_r^T x\|_2 = x^T U_r U_r^T x = x^T x = \|x\|_2 = 1$$

$\|\bar{y}\|_2 = 1$  כי  $y$  מוגבלת ב-1

כעת דיברנו על הערך

$$\forall x, y \in \mathbb{R}^r : (x^T \Sigma_r y) \leq \sigma_1 \|x\|_2 \|y\|_2 = \sigma_1$$

$$\Rightarrow x^T \Sigma_r y \geq -\sigma_1$$

$$\begin{aligned} & \text{לדוגמא, } x = (1, \dots, 0) \\ & y = (-1, \dots, 0) \end{aligned}$$

$$x^T \Sigma_r y = \sum_{i=1}^r \sigma_i x_i y_i = -\sigma_1$$

$$\Rightarrow \min_{x \in \mathbb{R}^m, y \in \mathbb{R}^n, \|x\|_2 = \|y\|_2 = 1} x^T A y = \min_{x, y \in \mathbb{R}^r, \|x\|_2 = \|y\|_2 = 1} x^T \Sigma_r y = -\sigma_1$$

הוכחה למשפט 1.1

$$\max_{\substack{x \in \mathbb{R}^n, y \in \mathbb{R}^n \\ \|x\|_2 = \|y\|_2 = 1}} (x^T V \Sigma_r V^T y) = \max_{\substack{x \in \mathbb{R}^r, y \in \mathbb{R}^r \\ \|x\|_2 = \|y\|_2 = 1}} (x^T \Sigma_r y)$$

הוכחה של המשפט. נניח ש-  $\Sigma_r \in \mathbb{R}^{r \times r}$

$$\Rightarrow (x^T \Sigma_r y) = \sum_{i=1}^r \sigma_i x_i y_i \leq \sigma_1 \sum_{i=1}^r |x_i y_i| = \sigma_1 |x^T y| \leq \sigma_1 \|x\|_2 \|y\|_2$$

ד

- א. מינימום
- ב. מקסימום

$$\Rightarrow \forall x, y \in \mathbb{R}^r, \|x\|_2 = \|y\|_2 = 1 : x^T \Sigma_r y \leq \sigma_1$$

נניח ש-  $x, y \in \mathbb{R}^r$  וקיים רקורסיבי  $\sigma_1 \geq \dots \geq \sigma_r$  מוגדרות על ידי:

$$x^T \Sigma_r y = \sigma_1$$

ובן-לכד, ניקח רגילה.  $x=y=e^{\frac{1}{2}} = (1, 0, \dots, 0)^T$  וpun

$$x^T \Sigma_r y = \sum_{i=1}^r \sigma_i x_i y_i = \sigma_1$$

$$\Rightarrow \max_{\substack{x \in \mathbb{R}^n, y \in \mathbb{R}^n \\ \|x\|_2 = \|y\|_2 = 1}} (x^T V \Sigma_r V^T y) = \max_{\substack{x \in \mathbb{R}^r, y \in \mathbb{R}^r \\ \|x\|_2 = \|y\|_2 = 1}} (x^T \Sigma_r y) = \sigma_1$$

$$A \in \mathbb{R}^{m \times n}$$

הוכיחו כי הערך המקסימלי מתקיים עבור  $x = u_1$ ,  $y = v_1$ . כלומר - עבור הוקטורים הסינגולריים המתאימים ל- $(A)$ .

$$\text{הזיהוי } f_{\sigma_1} \text{ כפונקציית סיבוב}$$

$$\sigma_1(A) = \max_{x \in \mathbb{R}^m, y \in \mathbb{R}^n, \|x\|_2 = \|y\|_2 = 1} x^T A y$$

נתקן ב- $x = u_1$ ,  $y = v_1$  ונקרא כה גודל שקיים מינימום של פונקציית סיבוב

$$\sigma_1 \text{ של } A \text{ הוא } \sigma_1 = u_1^T A v_1$$

$$\text{ולכן } x^T A y = u_1^T A v_1$$

(3)

השתמשו בתוצאה הנ"ל כדי להראות שעבור כל  $A, B \in \mathbb{R}^{m \times n}$  מתקיים:

$$\sigma_1(A + B) \leq \sigma_1(A) + \sigma_1(B)$$

$$\begin{aligned} \sigma_1(A+B) &= \max_{\substack{x \in \mathbb{R}^m, y \in \mathbb{R}^n \\ \|x\|_2 = \|y\|_2 = 1}} x^T (A+B) y \leq \max_{\substack{x \in \mathbb{R}^m, y \in \mathbb{R}^n \\ \|x\|_2 = \|y\|_2 = 1}} (x^T A y) + \max_{\substack{x \in \mathbb{R}^m, y \in \mathbb{R}^n \\ \|x\|_2 = \|y\|_2 = 1}} (x^T B y) = \\ &= \sigma_1(A) + \sigma_1(B) \end{aligned}$$

תהי מטריצה  $A \in \mathbb{S}^n$  (6)

נסמן ב- $\mathbb{S}^n$  את השורש של  $A$  שהוא מטריצה שמקיימת  $A = A^{\frac{1}{2}}A^{\frac{1}{2}}$ .

1. הוכחו של מטריצה  $A$  קיימש שורש ממשי  $A^{\frac{1}{2}}$  אם ורק אם  $A \geq 0$ .

$$x \in \mathbb{R}^n : x^T A x \geq 0 \Leftrightarrow \text{כל } i \text{ ו } j \text{ נסsat} \quad \Leftrightarrow A \geq 0$$

$$\lambda_i \in \mathbb{R}, i \in [n], \exists u_i \in \mathbb{R}^n, i \in [n] : A u_i = \lambda_i u_i, \exists U = [u_1 \dots u_n] \text{ such that } A = U \Lambda U^T \geq 0$$

$$A = U \Lambda U^T = U \underbrace{A^{\frac{1}{2}}}_{\text{I}} \underbrace{U^T}_{A^{\frac{1}{2}}} \cdot U \Lambda U^T = A^{\frac{1}{2}} \cdot A^{\frac{1}{2}}$$

$$A^{\frac{1}{2}} \text{ ק.מ.ר.}$$

2. נסמן ב- $A = U \Lambda U^T = \sum_{i=1}^n \lambda_i u_i u_i^T$  את הפירוק הספקטורי של  $A$ . בטאו באמצעותו את הפירוק הספקטורי של  $A^{\frac{1}{2}}$ .

$$\text{לע'ן } A = \Lambda^{\frac{1}{2}} \Lambda^{\frac{1}{2}} \text{ : } \Lambda \geq 0 \text{ (מכוסה)}$$

$$\Rightarrow A = U \Lambda^{\frac{1}{2}} \Lambda^{\frac{1}{2}} U^T = U \Lambda^{\frac{1}{2}} U^T U \Lambda^{\frac{1}{2}} U^T$$

$$BB = A \quad \text{נוצרת נסח}$$

$$\Rightarrow A^{\frac{1}{2}} = B = U \Lambda^{\frac{1}{2}} U^T$$

3.6

נסמן ב-  $A^{-\frac{1}{2}}$  את המטריצה ההופכית של  $A^{\frac{1}{2}}$ .  
 (3) נניח  $A$  מוגדרת חיובית. תהי  $\mathbb{S} \in \mathbb{S}^n$ .  
 נתבונן בבעיית האופטימיזציה הבאה:

$$\max_{x \neq 0} \frac{x^T B x}{x^T A x}$$

הוכיחו כי הערך האופטימלי של בעיה זו הוא  $\lambda_1(A^{-\frac{1}{2}} B A^{-\frac{1}{2}})$ .

$A = A^{\frac{1}{2}} \cdot A^{\frac{1}{2}}$  ו-  $x^T B x$  נסמן ב-  $f(x)$  ו-  $x^T A x$  נסמן ב-  $g(x)$ .

$$\max_{x \neq 0} \frac{x^T B x}{x^T A x} = \max_{x \neq 0} \frac{x^T B x}{x^T A^{\frac{1}{2}} A^{\frac{1}{2}} x} = \frac{x^T B x}{(A^{\frac{1}{2}} x)^T (A^{\frac{1}{2}} x)}$$

$B \in \mathbb{S}^n$

$$\max_{x \neq 0} \frac{(A^{-\frac{1}{2}} y)^T B (A^{-\frac{1}{2}} y)}{y^T y} = \lambda_1(A^{-\frac{1}{2}} B A^{-\frac{1}{2}})$$

## שאלה 7

יהיו  $A, B \in \mathbb{S}^n$ . ראיינו בהרצתה את הטענה הבאה:

אם  $B \geq A$  אז לפחות  $n$  מתקיימים:  $\lambda_i(A) \geq \lambda_i(B)$   $1 \leq i \leq n$

הוכח / הפרך:

$$\forall x \in \mathbb{R}^n : x^\top (A - B) \cdot x \geq 0 \Leftrightarrow A - B \geq 0 \quad \Leftrightarrow A \geq B \text{ ו } \lambda_i(A) \geq \lambda_i(B) \quad 1 \leq i \leq n$$

$$A = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}, B = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}, \lambda_1(A) \geq \lambda_1(B) = 2$$

$$1 = \lambda_2(A) \geq \lambda_2(B) = 1$$

$$(1, 4) \left( \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \right) \begin{pmatrix} 1 \\ 4 \end{pmatrix} = (1, 4) \begin{pmatrix} 2 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} 1 \\ 4 \end{pmatrix}$$

$$= (1, 4) \begin{pmatrix} 2 \\ -4 \end{pmatrix} = 2 - 16 = -14 < 0$$

לכן  $\lambda_1(A) \geq \lambda_1(B)$  ונראה  $A, B \in \mathbb{S}^n$

$A \geq B$  אם ורק אם  $A - B \geq 0$  ורשותו

```

def QR_division(A):
    z, Q = Grand_Shit(A)
    R = find_R(A, Q, z)

    return Q, R

def find_R(A, Q, z):
    R = np.array([[0 for _ in range(len(A[0]))] for _ in range(len(A[0])), float])
    Q = np.array(Q, float)
    A = np.array(A, float)
    for i in range(len(R)): # row
        for j in range(len(R[0])): # col
            if i == j:
                R[i][i] = math.sqrt(sum(f ** 2 for f in Z.T[i]))
            elif i < j:
                R[i][j] = inner_mul(Q.T[i], A.T[j])
    return R

def cal_proj(V1, V2):
    return (inner_mul(V1, V2) / inner_mul(V1, V1)) * V1

3 usages ✎ GilCaplan
def inner_mul(V1, V2):
    return sum(V1[i] * V2[i] for i in range(len(V1)))

1 usage ✎ GilCaplan
def normalize(V):
    V = np.array(V, float)
    x = math.sqrt(sum(V[i] * V[i] for i in range(len(V))))
    return np.array([v_i / x for v_i in V], float)
x = np.array([21, 11, 9, 6, 5, 4, 2, 1, 94, 91, 89, 85, 84, 16, 98])

np.set_printoptions(precision=2)
Q1, R1 = QR_division(M)
print("Q = , {Q1}, \n")
print("R = , {R1}, \n")
print("part 2:", Q1 @ Q1.T @ x)
# projection of x on S is equal to P @ P^T @ x
print("part 3", (np.eye(len(Q1)) - Q1 @ Q1.T) @ x)
# projection of x on S complement is (I - P @ P^T) @ x as proved in HW02 QB

```

```
Q = , [[ 0.21  0.18  0.19 -0.48 -0.23 -0.06 -0.26  0.   -0.18 -0.11]
 [ 0.28 -0.26  0.16  0.13 -0.08  0.54 -0.45 -0.3   0.21  0.04]
 [ 0.36 -0.32  0.29  0.27 -0.3   -0.09  0.15  0.04  0.12 -0.21]
 [ 0.   0.43  0.2   0.35 -0.02  0.03 -0.23  0.11  0.22 -0.41]
 [ 0.14  0.06  0.31 -0.28 -0.31 -0.09  0.38  0.23 -0.02 -0.1 ]
 [ 0.36 -0.08 -0.3   0.34  0.08  0.07 -0.05  0.61 -0.22  0.19]
 [ 0.   0.06  0.41  0.2   0.25  0.39  0.59 -0.04 -0.02  0.04]
 [ 0.14  0.43 -0.21  0.25  0.15 -0.07  0.08 -0.09  0.09 -0.02]
 [ 0.43 -0.02 -0.47 -0.38  0.12  0.29  0.31 -0.14  0.25 -0.08]
 [ 0.28  0.17  0.11 -0.06 -0.06  0.24 -0.13  0.16 -0.53  0.08]
 [ 0.5  -0.15  0.06  0.13  0.19 -0.61  0.01 -0.26  0.03  0.01]
 [ 0.14  0.12  0.35 -0.25  0.72 -0.04 -0.17  0.08 -0.01 -0.01]
 [ 0.14  0.36 -0.18 -0.04 -0.13  0.06  0.03  0.05  0.14 -0.42]
 [ 0.14  0.43  0.04  0.15 -0.23 -0.03  0.09 -0.46 -0.21  0.47]
 [ 0.07  0.18  0.16 -0.12 -0.13 -0.05 -0.08  0.34  0.63  0.56]],
```

```
R = , [[14.04 14.75 17.95 16.74  9.55 14.61 20.8   15.39 13.18 14.82]
 [ 0.   16.17  6.51  8.35  5.7   6.47  8.61  4.83  3.32  8.99]
 [ 0.   0.   16.17  5.01  4.3   4.62  2.88  7.57  1.16  9.92]
 [ 0.   0.   0.   12.4  -3.39  2.76  7.29  0.65 -2.03  2.34]
 [ 0.   0.   0.   0.   6.35  0.82 -2.1   1.3   -4.66  3.23]
 [ 0.   0.   0.   0.   0.   10.11 3.14  2.2   1.2   -0.15]
 [ 0.   0.   0.   0.   0.   0.   8.74 -0.62  1.28  1.6 ]
 [ 0.   0.   0.   0.   0.   0.   0.   9.24  5.84 -1.08]
 [ 0.   0.   0.   0.   0.   0.   0.   0.   7.34 -1.02]
 [ 0.   0.   0.   0.   0.   0.   0.   0.   0.   4.62]],
```

```
part 2: [60.98 24.87  6.06 12.49 31.24 31.14  0.91 40.73 95.81 38.16 69.24 89.69
 39.99 21.85 75.38]
part 3 [-39.98 -13.87   2.94  -6.49 -26.24 -27.14   1.09 -39.73  -1.81  52.84
 19.76  -4.69  44.01  -5.85  22.62]
```